# Universidade de Aveiro

## MPEI 2020/21

## 2º guião para avaliação

**Joaquim Andrade nº93432**

**Francisco Silva nº93400**

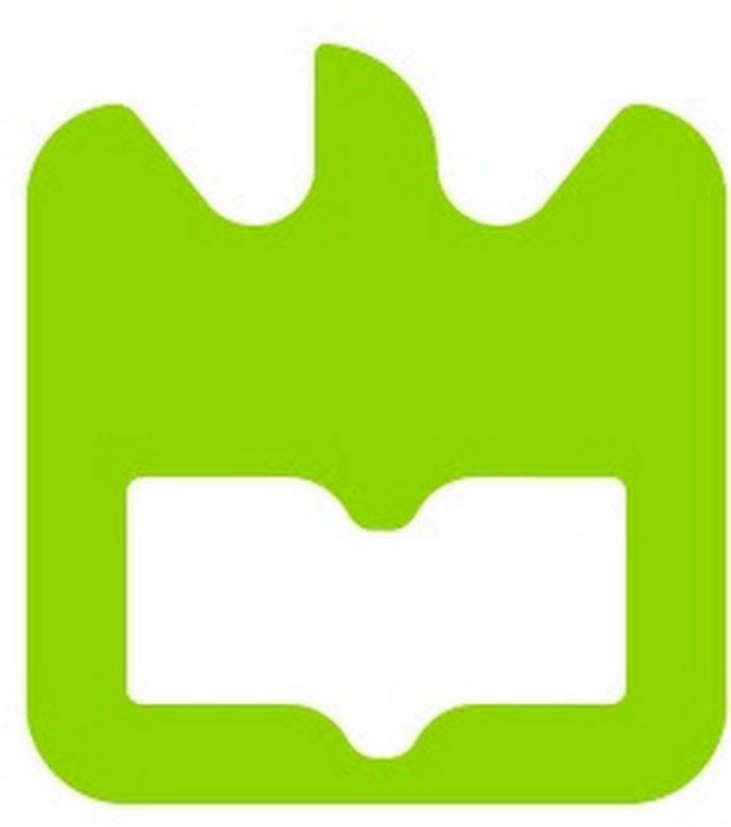

1.a)Abaixo encontra-se o código. Fizemos também uso da função, fornecida pelo docente, crawl, a qual alteramos para não passar o último argumento para a palavra. A palavra criada foi “a”.

```
% Random walk on the Markov chain
% Inputs:
% H - state transition matrix
% first - initial state
% last - terminal or absorving state
function state = crawl(H, first, last)
% the sequence of states will be saved in the vector "state"
% initially, the vector contains only the initial state:
    state = [first];

% keep moving from state to state until state "last" is reached:
    while (1)
        a=nextState(H, state(end));
        if (a== last)   %stops the atribution of the last state
to the word
            break;
        end
        state(end+1) = a;
    end
end
```

```
m=[0   1/3 0   1/4 0; %r
   1/2 0   1/2 1/4 0; %o
   0   1/3 0   1/4 0; %m
   1/2 0   1/2 0   0; %a
   0   1/3 0   1/4 0]; %.
%cria uma matriz de transição

basedados= ['r','o','m','a',' '];%cria caracteres na mesma
posição que na matriz

palavra= basedados(crawl(m,randi(4),5));%cria um caminho pela
matriz e passa-o para uma palavra
```

1.b) Foram geradas aproximadamente 117867 palavras não repetidas, ou seja aproximadamente 9/10 das palavras são repetidas. Os resultados das cinco palavras que mais apareceram foram:

```
'o'   0.0832810000000000

'a'   0.0622420000000000

'ro'  0.0418120000000000

'mo'  0.0414750000000000

'ra'  0.0313570000000000
```

Fazemos também uso da função crawl acima aqui. O código utilizado foi o seguinte:

```
m=[0   1/3 0   1/4 0; %r
   1/2 0   1/2 1/4 0; %o
   0   1/3 0   1/4 0; %m
   1/2 0   1/2 0   0; %a
   0   1/3 0   1/4 0]; %.
%cria uma matriz de transição
a=cell(10e5, 1);%aloca espaço para 10e5 palavras em cell
for i=1: 10e5   %ciclo cria e aloca 10e5 palavras no cell criado
anterior
    a{i}=basedados(crawl(m,randi(4),5)) ;
end
pD= length(unique(a));  %número de palavras não repetidas
Mpu= unique(a);
[uc, ~, idc] = unique(a);
counts= accumarray(idc, ones(size(idc)));

M= cell(pD, 2);
for i=1:pD
    M(i,1)=Mpu(i);  %aloca as palavras não repetidas
    M(i,2)= num2cell(counts(i)/10e5); %aloca a probabilidade de
se repetirem no array original
end
f=cell(5,2);%5 palavras mais usadas e probabilidade
M=sortrows(M,2); % ordena as probabilidades
for i=1: 5
    f(i,1)= M(pD-i+1,1); %guarda aas primeiras 5 palavras
    f(i,2)= M(pD-i+1,2); %guarda as primeiras 5 probabilidades
end
```

1.c)Cálculos das probabilidades teóricas das 5 palavras mais geradas:

```
'o'   0,25*1/3 = 0,083333333

'a'   0,25*0,25 = 0,0625

'ro'  0,25*0,5*1/3 = 0,041666666

'mo'  0,25*0,5*1/3 = 0,041666666

'ra'  0,25*0,5*0,25 = 0,03125
```

Comparando estes valores com os obtidos na alínea anterior observamos que são muito idênticos e por isso podemos concluir que a simulação foi bem sucedida.

1.d)Ao código da pergunta 1.b) adicionámos o seguinte excerto de código que abre o ficheiro de palavras, interseta-o com as palavras geradas e com as probabilidades de cada palavra ser gerada. Essa probabilidade deu 0.3531.

```
fid=fopen('wordlist-preao-20201103.txt');
data=textscan(fid,'%s');
fclose(fid);
g= data{1}(1:end);%abrir e ler o ficheiro para uma célula
```

```
a=0;
h=intersect(g, Mpu);%interseta g com as palavras geradas
for i=1: length(Mpu)
    if ismember(M(i,1), h)==1%se existir uma palavra em M
        a=a+cell2mat(M(i,2)); %somamos a probabilidade dessa
palavra
    end
end
```

1.e)Esta função crawl não adiciona o ultimo estado à palavra e para quando n é alcançado.

```
function state = crawl2(H, first, last, n)%add n

    state = [first];
    d=1;
    while (1)
        a=nextState(H, state(end));
        if (a== last || n==d)%stops the atribution of the last
state to the word
            break;
        end
        state(end+1) = a;
        d=d+1;
    end
end
```

1.f) Usando a função resolvida anteriormente, juntamente com o código também resolvido anteriormente, chegámos aos seguintes resultados:

n=8 : 0.3534

n=6 : 0.3655

n=4 : 0.4977

Podemos observar que a probabilidade de ser gerada uma palavra válida em português tende a aumentar à medida que diminuímos o tamanho máximo das palavras. Isto vai também ao encontro do que foi observado no exercício 1b), visto que as palavas mais geradas são as palavras com menor tamanho possível. No exercício 1d) foi registada uma probabilidade de 0.3531 que tende a aumentar reduzindo o tamanho máximo como foi possível concluir no exercício 1f).

2- Tal como na função 1.f), usámos o código já desenvolvido, e alterámos apenas a matriz de transição para a seguinte:

```
m=[0   0.3 0   0.3 0; %r
   0.3 0   0.3 0.1 0; %o
   0   0.2 0   0.2 0; %m
   0.7 0   0.7 0   0; %a
   0   1/2 0   0.4 0]; %.
```

As nossas conclusões foram as seguintes:

N=∞ : 0.5183

n=8 : 0.5205

n=6 : 0.5362

n=4 : 0.6507

Tal como os resultados obtidos anteriormente podemos observar a tendência de a probabilidade aumentar ao reduzir o tamanho máximo das palavras.

Comparando as matrizes de transição usadas podemos observar que as probabilidades tando entre o estado 'a' e '.' como entre o estado 'o' e '.' são significativamente maiores em relação às do exercício anterior. Assim existe também uma maior probabilidade de uma palavras geradas ser de tamanho menor daí as probabilidades de ser gerada uma palavra válida em português obtidas neste exercício serem maiores quando comparadas com as obtidas no exercício anterior.

3-Retirámos as percentagens em relação às 10e5 palavras criadas e usámos apenas as palavras que usam as letras 'a', 'o', 'm', 'r' e que estão no dicionário e na lista de palavras geradas e repetidas (519051 palavras). Dessas:

começadas por a: 0.3546

começadas por m: 0.2598

começadas por o: 0.3128

começadas por r: 0.0728

Foi adicionado o seguinte código(depois de retirada a divisão por 10e5):

```
pa=0;
pm=0;
pr=0;
po=0;

for i=1: length(Mpu)
    if ismember(M(i,1), h)==1 && M{i,1}(1)== 'a' %se existir uma
palavra em M e a primeira letra for a
        pa=pa+cell2mat(M(i,2)); %somamos o numero de palavras
começadas por a
    end
    if ismember(M(i,1), h)==1 && M{i,1}(1)== 'm' %se existir uma
palavra em M e a primeira letra for m
        pm=pm+cell2mat(M(i,2)); %somamos o numero de palavras
começadas por m
    end
    if ismember(M(i,1), h)==1 && M{i,1}(1)== 'o' %se existir uma
palavra em M e a primeira letra for o
        po=po+cell2mat(M(i,2)); %somamos o numero de palavras
começadas por o
    end
    if ismember(M(i,1), h)==1 && M{i,1}(1)== 'r' %se existir uma
palavra em M e a primeira letra for r
```

```
        pr=pr+cell2mat(M(i,2)); %somamos o numero de palavras
começadas por r
    end
end
pt= pa+pm+po+pr; % obter o numero de palavras totais
pa= pa/pt;%probabilidades de começar em a e com as limitações
pm= pm/pt;
po= po/pt;
pr= pr/pt;
```

Usando estas probabilidades para criar o estado inicial da matriz de transição obtivemos um aumento de aproximadamente 10% da probabilidade de uma palavra gerada ser uma palavra em português sem qualquer limite, por sua vez os outros resultados para diferentes n foram os seguintes:

n=∞ :0.6149

n=8 :0.6168

n=6 :0.6380

n=4 :0,7310

O código usado para alterar a letra inicial foi o seguinte:

```
n=4;
m=[0   0.3 0   0.3 0; %r
   0.3 0   0.3 0.1 0; %o
   0   0.2 0   0.2 0; %m
   0.7 0   0.7 0   0; %a
   0   1/2 0   0.4 0]; %.

%cria uma matriz de transição
basedados= ['r','o','m','a',' '];%cria caracteres na mesma
posição que na matriz
pa= 0.3546;
pm= 0.2598;
po=0.3128 ;
pr=0.0728;

a=cell(10e5, 1);%aloca espaço para 10e5 palavras em cell
for i=1: 10e5   %ciclo cria e aloca 10e5 palavras no cell criado
anterior
    prand=rand();
    if(pa>prand)
        t=4;
    elseif (pm+pa)>prand
        t=3;
    elseif (pm+pa+po)>prand
        t=2;
    else
        t=1;
    end
```

```
    a{i}=basedados(crawl2(m,t,5,n)) ;
end
```

4-Alterando a matriz da pergunta anterior para a seguinte:

```
m=[0   0.3 0   0.3 0; %r
   0.3 0   0.3 0.1 0; %o
   0.1 0.2 0   0.2 0; %m
   0.6 0   0.7 0   0; %a
   0   0.5 0   0.4 0]; %.
```

Obtivemos os seguintes resultados da probabilidade de criar palavras em português:

n=∞ :0.6039

n=8 :0.6051

n=6 :0.6230

n=4 :0.7159

Em relação aos exercícios anteriores, podemos observar uma redução de aproximadamente 2% de eficiência em todos os tamanhos limitantes das palavras. Estes resultados podem ser atribuídos à grande diferença entre as palavras que contêm “rm” em relação à combinação do qual o retiramos, mas também pode ser devido a ser uma transição entre dois estados não terminais, o que faz com que a palavra, “assumindo que começa em r”, tenha no mínimo 3 letras. “rm” não é normalmente um início típico de uma palavra portuguesa, o que dá que uma palavra começada com “rm” tenha sempre no mínimo quatro letras o que pode ser atribuído à diminuição da eficiência.

5-